Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

Ciencia de Datos

Clase 13

Introducción al Aprendizaje Automático

Material teórico — Bloque 1 (40 minutos)

Con esta clase comienza un nuevo bloque de la carrera: dejamos atrás la programación clásica de computadoras y entramos al paradigma del entrenamiento de modelos a partir de datos. El objetivo de este bloque teórico es que puedan explicar, con sus propias palabras, qué es (y qué no es) el Machine Learning, y reconocer las tres grandes familias de algoritmos de aprendizaje.

1. ¿Qué es el Machine Learning?

El Aprendizaje Automático (Machine Learning, ML) no es magia ni ciencia ficción: es un conjunto de métodos para construir modelos matemáticos a partir de datos. Un modelo es, en esencia, una función que relaciona ciertas variables de entrada con una salida de interés, y esa función no la escribe una persona a mano: se estima automáticamente a partir de ejemplos.

La idea central es simple: en lugar de decirle a la computadora exactamente qué reglas debe aplicar, le mostramos muchos casos ya resueltos y dejamos que el propio algoritmo descubra la relación matemática que los explica.

1.1 Programación tradicional vs. Machine Learning

La diferencia clave está en qué es la entrada y qué es la salida del proceso:

- Programación tradicional: el programador escribe reglas lógicas (código) → esas reglas se aplican sobre los datos de entrada → la computadora produce respuestas.
- Machine Learning (entrenamiento): ingresamos datos históricos y las respuestas deseadas para esos datos → un algoritmo de aprendizaje detecta los patrones que los conectan → la computadora genera las reglas (el modelo), que luego usaremos para predecir sobre casos nuevos.

En otras palabras: en la programación tradicional las reglas son un insumo; en Machine Learning, las reglas son el resultado que queremos obtener.

Etapa	Programación Tradicional	Machine Learning (Entrenamiento)
Entrada 1	Reglas (código escrito por el programador)	Datos históricos
Entrada 2	Datos	Respuestas deseadas (etiquetas)
Proceso	La computadora ejecuta las reglas sobre los datos	El algoritmo de aprendizaje detecta patrones entre datos y respuestas
Salida	**Respuestas**	**Reglas / Modelo (para predecir el futuro)**

Un ejemplo concreto: para detectar spam de forma tradicional, un programador debería anticipar y codificar a mano cientos de reglas ("si contiene la palabra 'premio' y un signo de exclamación, marcar como spam"). Con Machine Learning, en cambio, se le muestran al algoritmo miles de correos ya etiquetados como "spam" o "no spam", y es el propio algoritmo el que aprende qué combinaciones de palabras y patrones son indicio de spam.

1.2 ¿Por qué entrenamos en lugar de programar?

Hay problemas para los que resulta imposible o muy costoso escribir las reglas a mano: reconocer una cara en una foto, traducir un idioma o predecir el precio de una vivienda involucran demasiadas variables y combinaciones como para anticiparlas todas con lógica explícita. Cuando existen datos históricos suficientes, es más eficiente dejar que el modelo aprenda el patrón directamente de los ejemplos.

2. La taxonomía del aprendizaje: tipos de algoritmos

No todos los algoritmos de Machine Learning aprenden de la misma manera. La clasificación más usada distingue tres grandes familias según qué tipo de información reciben durante el entrenamiento: Aprendizaje Supervisado, Aprendizaje No Supervisado y Aprendizaje por Refuerzo.

2.1 Aprendizaje Supervisado (Supervised Learning)

En el aprendizaje supervisado, el sistema aprende a estimar una función matemática bajo la guía de un "supervisor": un conjunto de datos donde para cada entrada ya conocemos la salida correcta (la etiqueta). El algoritmo compara sus propias predicciones con la respuesta real y ajusta el modelo para reducir el error.

Se subdivide en dos tipos, según la naturaleza de la variable que queremos predecir:

	Regresión	Clasificación
Tipo de variable objetivo	Continua / cuantitativa	Categórica / cualitativa
Pregunta típica	¿Cuánto? ¿Cuál será el valor?	¿Cuál clase? ¿A qué categoría pertenece?
Ejemplos	Precio de una casa, temperatura del día, ventas en dólares	Spam / No Spam, tumor benigno / maligno

Una forma rápida de distinguirlos: si la respuesta se puede ubicar en una recta numérica (y admite valores intermedios), es regresión. Si la respuesta es una entre un conjunto finito de categorías, es clasificación.

2.2 Aprendizaje No Supervisado (Unsupervised Learning)

Acá trabajamos "a ciegas", sin variable de respuesta: solo contamos con las características de entrada, sin ninguna etiqueta que le diga al algoritmo cuál es la respuesta correcta. El objetivo no es predecir un valor, sino dejar que el propio conjunto de datos "hable por sí mismo" y revele estructuras, agrupaciones o relaciones ocultas.

Dos aplicaciones típicas:

- Clustering (agrupamiento): identificar grupos naturales de observaciones similares entre sí. Ejemplo: segmentar clientes según sus hábitos de compra, sin saber de antemano cuántos segmentos existen ni cómo se llaman.
- Reducción de dimensiones: resumir muchas variables en unas pocas que conserven la mayor parte de la información, útil para visualizar datos complejos o simplificar otros modelos.

La diferencia clave con el aprendizaje supervisado: no hay una "respuesta correcta" contra la cual comparar; el éxito se evalúa por la coherencia interna de los grupos o patrones descubiertos.

2.3 Aprendizaje por Refuerzo (Reinforcement Learning)

Es el paradigma más distinto de los dos anteriores. Acá no hay un dataset fijo de entrada-salida ni de observaciones sin etiquetar: hay un agente que toma decisiones secuenciales dentro de un entorno dinámico, y aprende por ensayo y error a través de un sistema de recompensas y penalizaciones.

El ciclo básico funciona así: el agente observa el estado del entorno, elige una acción, el entorno responde con un nuevo estado y una recompensa (positiva o negativa), y el agente ajusta su estrategia para maximizar la recompensa acumulada a lo largo del tiempo.

- Ejemplos típicos: un agente que aprende a jugar al ajedrez o al Go, un robot que aprende a caminar, un sistema que optimiza el consumo energético de un edificio.

A diferencia del aprendizaje supervisado, aquí nadie le dice al agente cuál era la "acción correcta" en cada paso: solo recibe una señal de recompensa que puede llegar mucho después de la acción que la originó, lo cual hace que este tipo de aprendizaje sea considerablemente más complejo de entrenar.

2.4 Cuadro comparativo de la taxonomía

	Supervisado	No Supervisado	Por Refuerzo
¿Hay etiquetas?	Sí, entrada + salida	No, solo entradas	No; hay recompensas
Objetivo	Predecir una salida	Descubrir estructura	Maximizar recompensa
Ejemplo	Predecir precio de venta	Segmentar clientes	Agente que juega al ajedrez

3. Ideas clave para retener

- Machine Learning = construir modelos matemáticos a partir de datos, no magia ni programación de reglas explícitas.
- En programación tradicional las reglas son la entrada; en ML, las reglas (el modelo) son la salida del proceso.
- Supervisado: hay etiquetas → Regresión (salida continua) o Clasificación (salida categórica).
- No supervisado: no hay etiquetas → se buscan patrones o estructuras ocultas (clustering, reducción de dimensiones).
- Por refuerzo: un agente aprende por ensayo y error mediante recompensas, sin un dataset fijo de antemano.

4. Preguntas de repaso

- ¿Cuál es la diferencia fundamental entre el flujo de la programación tradicional y el del entrenamiento en Machine Learning?
- Dar dos ejemplos propios (no vistos en clase) de un problema de regresión y dos de clasificación.
- ¿Por qué se dice que en el aprendizaje no supervisado "dejamos que el dataset hable por sí mismo"?
- En aprendizaje por refuerzo, ¿qué rol cumplen el agente, el entorno y la recompensa?

- Pensar un problema de su interés y decidir a cuál de los tres tipos de aprendizaje correspondería resolverlo, justificando la elección.