Aprendizaje No Supervisado (Clustering II)

Clase 15 — Clustering Jerárquico y Algoritmos Basados en Densidad (DBSCAN)

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial — Duración: 80 minutos (40 teóricos / 40 prácticos)

De acuerdo con el diseño curricular oficial y la bibliografía de referencia (An Introduction to Statistical Learning y Python Data Science Handbook), esta clase profundiza en los métodos avanzados de agrupamiento no supervisado, abordando el Clustering Jerárquico y los Algoritmos Basados en Densidad (DBSCAN). El objetivo es superar las limitaciones de K-Means cuando los clusters presentan formas geométricas complejas o cuando no se desea definir a priori un número K de grupos.

1. Bloque Teórico: Jerarquías y Densidades (40 minutos)

A. Limitaciones de K-Means (el punto de partida)

- Presuposición de forma: K-Means asume que los clusters son esféricos y de tamaño similar.
- Sensibilidad a ruido y outliers: obliga a todas las observaciones a pertenecer a un cluster, distorsionando los centroides en presencia de valores atípicos.
- Elección rígida de K: requiere fijar el número de clusters antes de comenzar el entrenamiento.

B. Clustering Jerárquico Aglomerativo (Bottom-Up)

Concepto. A diferencia de K-Means, no requiere definir K de antemano. Comienza tratando a cada una de las n observaciones como un cluster individual. De manera iterativa, calcula la disimilitud entre clusters y fusiona los dos más cercanos, hasta que todas las observaciones quedan agrupadas en un único tronco.

El Dendrograma. Es una representación gráfica en forma de árbol invertido que resume el proceso de fusiones.

- Interpretación: la distancia vertical (altura) a la que dos ramas se unen indica cuán disímiles son entre sí las observaciones o grupos.
- Realizar un corte horizontal a una determinada altura permite obtener cualquier número deseado de clusters.

Criterios de Enlace (Linkage). Determinan cómo se mide la distancia entre dos grupos de observaciones:

Criterio	Medida	Efecto característico
Complete (Máximo)	Distancia máxima entre cualquier punto del cluster A y cualquier punto del cluster B.	Tiende a producir clusters compactos y balanceados.
Single (Mínimo)	Distancia mínima entre puntos de ambos clusters.	Puede generar "cadenas" de puntos (trailing clusters), uniendo observaciones de a una.
Average (Promedio)	Distancia promedio entre todos los pares de puntos de ambos clusters.	Solución intermedia entre Complete y Single.
Centroid	Distancia entre los centroides de ambos grupos.	Puede producir inversiones en el dendrograma.

C. Algoritmos Basados en Densidad: DBSCAN

Concepto. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa observaciones según la concentración local de puntos en el espacio.

Hiperparámetros clave

- eps (ε): el radio de vecindad alrededor de un punto.
- min_samples: número mínimo de puntos requeridos dentro del radio ε para considerar que esa región es densa.

Tipos de puntos

Tipo de punto	Definición
Núcleo (Core)	Tiene al menos min_samples vecinos dentro de su radio ε.
Borde (Border)	Tiene menos de min_samples vecinos, pero está dentro del radio ε de un punto núcleo.
Ruido (Noise / Outlier)	No es núcleo ni borde. DBSCAN lo clasifica automáticamente como -1 (outlier), sin forzarlo a ningún grupo.

Ventajas principales

- Descubre clusters de formas arbitrarias (anillos, espirales, formas no cóncavas).
- No requiere especificar el número de clusters de antemano.

2. Síntesis: K-Means vs. Jerárquico vs. DBSCAN

Aspecto	K-Means	Jerárquico	DBSCAN
Requiere K previo	Sí	No (se elige al cortar el dendrograma)	No
Forma de clusters	Esférica	Depende del linkage	Arbitraria
Maneja outliers	No	No de forma explícita	Sí (los marca como ruido, -1)
Hiperparámetros clave	K	Métrica de distancia y linkage	eps y min_samples